

AI Research Assistant (RAG + Agents + Web Search)

Proyecto recomendado para entrevistas de AI Engineer

Un asistente inteligente capaz de responder preguntas sobre documentos, buscar información actualizada en Internet, citar fuentes, resumir artículos, comparar documentos, ejecutar herramientas y mantener memoria conversacional.

¿Por qué este proyecto?

Demuestra habilidades en LLMs, RAG, embeddings, bases vectoriales, tool calling, agentes, APIs, Docker, cloud y evaluación de prompts.

Arquitectura

Frontend (React/Next.js) → FastAPI Backend → Agent Orchestrator (LangGraph) → RAG / Search / Tools → Vector DB / Web Search / APIs

Funcionalidades

1. Chat inteligente. 2. Subida y consulta de PDFs. 3. Búsqueda web con fuentes. 4. Comparación de documentos. 5. Generación de reportes. 6. Memoria conversacional.

Tecnologías recomendadas

Backend: Python + FastAPI. IA: OpenAI, Anthropic, LangGraph. Vector DB: Chroma, Weaviate o Pinecone. Frontend: React / Next.js. Base de datos: PostgreSQL. Observabilidad: LangSmith. Infraestructura: Docker + AWS/Azure.

Extras que impresionan en entrevistas

Streaming de respuestas, citas, evaluación automática de calidad, soporte para múltiples modelos (GPT, Claude, Gemini) y monitoreo.

Impacto

Un AI Research Assistant completo es uno de los proyectos más sólidos para demostrar capacidades de AI Engineering en entrevistas modernas.